

# Übung Künstliche Neuronale Netzwerke

## Wintersemester 2015/2016

- ① Abgabe am 09. 12. 2015 bis Ende der Übung handschriftlich auf Papier (1x pro Person)
- ② Abgabe bis 16. 12. 2015, 23:55 Uhr im Moodle-Kurs (1x pro Gruppe)

### 3. Übungsblatt vom 02. 12. 2015

#### 3.1 Lineare Diskriminanten

Gegeben sei die folgende lineare Diskriminante:

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} -2 & -5 & 3 \\ 2 & 0 & 1 \\ 2 & -2 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ 1 \end{pmatrix}$$

- a) Zeichnen Sie das zugehörige Netzwerkdiagramm. Beschriften Sie die Kanten mit den Werten der entsprechenden synaptischen Gewichten. 2P ①
- b) Zeichnen Sie die Entscheidungsregionen  $R_1, R_2$  und  $R_3$  in ein Koordinatensystem. Dabei ist  $R_1$  die Region, in der  $y_1$  maximal ist usw. 5P ①

Berechnen Sie dazu zunächst die Geraden, auf denen zwei der  $y_i$  gleich sind und zeichnen Sie diese ein. Dadurch wird die Ebene in 6 Teile  $T_1 \dots T_6$  eingeteilt. Entscheiden Sie für jedes  $T_j$ , welches  $y_i$  maximal ist. Durch Zusammenfassen der entsprechenden  $T_j$  erhalten Sie  $R_1, R_2$  und  $R_3$ .

### 3.2 Gradientenabstieg

Betrachten Sie folgende Fehlerfunktion:

$$E(\underline{w}) = 1 - e^{-\frac{w_1^2 + w_2^2 + w_3^2}{\beta}} - \alpha(\cos(w_1) \cos(w_2) \cos(w_3) - 1)$$

- a) Berechnen Sie den Gradienten  $\nabla E(\underline{w})$ . Für welche Beziehung von  $\alpha$  und  $\beta$  gibt es ein lokales Minimum bei  $\underline{w}_{krit} = \underline{0}$ ? 5P ①

Hinweis: Ein hinreichendes Kriterium für ein lokales Minimum ist, wenn der Gradient  $\nabla E(\underline{w}_{krit}) = \underline{0}$  und die Hesse-Matrix der zweiten Ableitungen  $H(E(\underline{w}_{krit}))$  positiv definit ist, d.h. nur positive Eigenwerte besitzt.

$$H(E(\underline{w})) = \begin{pmatrix} \frac{\partial^2 E}{\partial w_1^2} & \frac{\partial^2 E}{\partial w_1 \partial w_2} & \frac{\partial^2 E}{\partial w_1 \partial w_3} \\ \frac{\partial^2 E}{\partial w_2 \partial w_1} & \frac{\partial^2 E}{\partial w_2^2} & \frac{\partial^2 E}{\partial w_2 \partial w_3} \\ \frac{\partial^2 E}{\partial w_3 \partial w_1} & \frac{\partial^2 E}{\partial w_3 \partial w_2} & \frac{\partial^2 E}{\partial w_3^2} \end{pmatrix}$$

- b) Schreiben Sie jeweils eine Funktion, die den Fehler  $E$  und den Gradienten  $\nabla E$  für einen gegebenen Gewichtsvektor  $\underline{w}$  und ein gegebenes  $\alpha$  berechnet. 2P ②

Der Gradientenabstieg erfolgt durch die Änderung des Gewichtsvektors  $\underline{w}$ . Die Änderung  $\Delta \underline{w}$  wird berechnet mit:

$$\Delta \underline{w} = -\eta \cdot \nabla E(\underline{w})$$

- c) Schreiben Sie eine Funktion, die durch einen Gradientenabstieg für eine gegebene Initialgewichtung  $\underline{w}_{init}$  und gegebene Lernrate  $\eta$  ein Minimum der Fehlerfunktion  $E(\underline{w})$  sucht und zurückgibt. Definieren Sie ein geeignetes Abbruchkriterium für den Gradientenabstieg. 4P ②
- d) Wählen Sie  $\alpha = 0.5$  und  $\beta = 500.0$ . Starten Sie den Gradientenabstieg mehrfach mit zufälligen Werten für  $\underline{w}_{init}$  aus dem Bereich  $[-10, 10]^3$  und betrachten Sie die resultierenden Gewichtsvektoren  $\underline{w}$  und deren Fehler  $E(\underline{w})$ . Variieren Sie die Lernrate  $\eta$  im Bereich  $[0.01, 10.0]$ . Für welche Werte von  $\eta$  divergiert das Verfahren? Was beobachten Sie in Bezug auf die Laufzeit? 3P ②
- e) Was geschieht für  $\alpha = -0.05$ ,  $\beta = 500.0$  und  $\eta = 0.01$  bei  $\underline{w}_{init} = \underline{0}$  und was bei  $\underline{w}_{init} = (1, 1, 0)^T$ ? Wird ein Minimum erreicht, und wenn nicht, warum? 1P ②